

# Някои бележки по прогнозирането на фондовите пазари

## Въведение

Как да се предвиди цената на акциите, все още е горещ изследователски проблем за инвеститорите и изследователите във финансовата област. Прогнозирането на цените на акциите се превръща в изключително предизвикателна задача поради високия шум, нелинейността и нестабилността на данните от времеви редове на цената на акциите. Основната идея на всички усилия в тази насока е хипотезата за ефективния пазар, която казва, че цената на акциите може да бъде предвидена от историческите данни за търговията. Специалистите все по-често поглеждат към широките набори съвременни възможности предоставяни от дълбокото машинно обучение и все по-успешно прилагат методите му. Повечето модели ползват разточителен набор от данни, включващи данни за търговията на конкретната акция, данни за индекси, валути, финансово-счетоводна информация, данни за макроикономически показатели и.н. Част от моделите се обучават и върху данни свързани със сентимента на пазара, като новини, туйтове, постове в социални мрежи. Има конструирани и сентимент индикатори, които могат да бъдат ползвани директно в съвременните невронни мрежи.

Целта на този проект е да се анализира ефективността на различни модели за прогнозиране върху данни от фондовия пазар и да се предскаже бъдещата цена на дадена акция.

## Методология

### 1. Данни

Моделите биват захранвани с два вида данни, оформени в два главни сета (**stocks\_df.csv** и **company\_dataset\_ts.csv**).

**Company\_dataset\_ts.csv** съдържа данните (под формата на времеви редове с 30 дневни прозорци на цената на затваряне) за конкретна компания (на случаен принцип бе избрана *Advanced Micro Devices, Inc. AMD*), както и седем изчислени индикатори. В **stocks\_df.csv** са събрани данни за 85 други характеристики, включващи индекси, валути, инфлационни индикатори, криптовалути, съкровищни бондове, ETFs, взаимни фондове, както и данни за други 50 компании от S&P 500. Пълен списък с ползваните данни, както и източниците на данни са предоставени в **get\_data\data\indicators\_list.csv**. Основния източник на данни е Yahoo Finance. Данните са подложени на задълбочен анализ, като допълнително е изготвен анализ за корелации, хетероскедастичност, серийни корелации и др. Направена е оценка на важните характеристики посредством PCA и XGBoosting, която по-късно не беше приложена, предвид оскъдното количество данни. Подбрана е извадка от 2267 наблюдения обхващащи периода от 2013 до 2021 г. Данните са разделени на трениращи и тестови в съотношение 85%:15% (1926, 341). Част от трениращите данни (около 20% - 22%) се ползват за валидация.

Основни моменти от събирането, анализа, визуализацията и подготовката на данните може да се намерят в **get\_data\SMP\_GatheringData.ipynb** и **get\_data\SMP\_Data\_Analysis.ipynb**.

Част от подготовката на данните е изнесена в основните файлове (**Stock\_Market\_Price\_Predictor\_Base\_Models.ipynb** и **Stock\_Market\_Price\_Predictor\_Hybrid\_Models.ipynb** в главната директория на проекта). Данните за трениране са размесени на случаен принцип<sup>1</sup>. Данните за тестване следват времевата си хронология, за да може моделите да бъдат оценени максимално близо до реалните работни условия. Следва min-max нормализация на данните и преоразмеряване, подходящо за вход в невронните архитектури.

### 2. Основни архитектури

Преди конструирането на хибридните модели са тествани няколко архитектури върху различните канали от данни. Основното внимание е насочено към LSTM и GRU, като по-съвременния и подобрен вариант на рекурентна невронна архитектура.

Рекурентната невронна мрежа (RNN) е вид невронна мрежа, която използва последователни данни или данни от времеви серии. Тези алгоритми за дълбоко обучение обикновено се използват за редовни или времеви проблеми, като езиков превод, обработка на естествен език, разпознаване на реч и надписи на изображения. RNN решават проблема със „забравянето“ на


---

<sup>1</sup> Фондовите пазари са характерни с оформянето на дългосрочни трендове. Избирането на подход без размесване на времеви серии не доведе до удовлетворителни резултати, тъй като Ковид кризата през последните години изкриви пазарите в голяма степен. Размесването на трениращите данни донякъде не позволи на моделите да заучат предходните по-стабилни дългосрочни трендове.

информацията. Изходите на невронните елементи имат обратни връзки с невроните на предишните слоеве. Това води до възможността за отчитане на резултатите от преобразуването на информацията от невронната мрежа от предходния етап.

Биологичната интелигентност обработва информацията постепенно, като същевременно поддържа вътрешен модел на това, което обработва, изграден от минала информация и непрекъснато актуализиран при постъпване на нова информация. Повтарящата се невронна мрежа (RNN) приема същия принцип, макар и в изключително опростена версия. Тя обработва последователностите и поддържа състояние, което съдържа информацията относно това, което е видяла досега. Невронната клетка на RNN има вида, показан на Фигура 1.

## Recurrent Neural Network (RNN), Long-Short Term Memory (LSTM) & Gated Recurrent Unit (GRU)



Фигура 1

Простите RNN имат сериозен проблем: въпреки че теоретично би трябвало да може да се запази в момент  $t$  информацията от предходните времеви стъпки, подобни по-дългосрочни зависимости се оказват невъзможни за научаване на практика. Това се дължи на проблема с изчезващия градиент, ефект, който е подобен на това, което се наблюдава при неповтарящи се мрежи, които са с голяма дълбочина.

## LSTM

Мрежите за дългосрочна памет LSTM, са специален вид RNN, способни да учат по-дългосрочни зависимости. Всяка LSTM има два входа, по които получава текущи данни и предходно състояние(контекст) и два изхода, от които излизат трансформирани данни и контекст. В самата клетка данните и контекста минават през няколко различни операции.

В LSTM, в повтарящия се модул, вместо да има един слой (than в RNN), има четири слоя, всеки с различно предназначение (Фигура 1). Основна ключова роля за този тип клетки е остта  $t-1 \rightarrow C_t$ , чието предназначение е да съхрани част от контекста на клетката и да го пренесе непроменен до следващата. LSTM има четири от тези порти, за да защитава и контролира състоянието на клетката.

Разгледана на стъпки, математиката, която стои зад всяка от тях е описана на фигурата. Първият сигмоид „гейт на забравяне“. Решава каква част от информацията ще се „забрави“. В следващата стъпка се преценява, каква нова информация ще се съхранява в състоянието на клетката. Става на два етапа. Първо, сигмоидният слой, наречен "входен гейт", решава кои стойности ще бъдат актуализирани. След това слой  $\tanh$  създава вектор от нови кандидат-стойности на състоянието. В следващата стъпка двата резултата се комбинират и следва актуализация на състоянието („актуализиращ гейт“). Данните минават през още един пласт (формиран от сигмоид и  $\tanh$ ) наречен „изходна порта“

## GRU

GRU е по-опростена и рационализирана версия на архитектурата LSTM. При този вид клетка вътрешните слоеве са намалени на три, а гейтовете за вход и забравяне са съчетани в единен гейт за „актуализиране“. GRU става все по-популярен.

## Bidirectional RNN

Двупосочният RNN е често срещан вариант на RNN, който може да предложи по-голяма производителност от обикновения RNN при определени задачи. Двупосочният RNN използва две редовни RNN, които може да са слоевете GRU и LSTM. Чрез обработка на последователностите и в двете посоки, двупосочния RNN може да улови модели, които могат да бъдат пренебрегнати от еднопосочния RNN.

От особена важност при работа с двупосочни модели , особено при решаване на задачи за прогнозиране, е да не се допуска обучение с валидационни данни, тъй като архитектурата им предполага „надникване в бъдещето “. Ако се ползват за работа с времеви серии може да бъде ползван най-много или в трениращите данни или въобще, по начин, който не позволява връщане на информация от „бъдещето“. Може да намери приложение в архитектури енкодер/декодер, като енкодер, който извежда контекстен междинен вектор. В проекта този Bidirectional беше тестван от чисто любопитство и представянето му с тестови данни беше най-слабо.

### 3. Метрики

При решаване на регресионни задачи обичайната мярка за оценка на загубата е средната квадратична грешка (MSE), а не средната абсолютна грешка (MAE), защото за разлика от MAE, тя е гладка около нулата и като такава има дефинирана производна там. Това е от съществено значение при изчисляване на градиента.

По-ниската стойност на MAE и MSE предполага по-висока точност на регресионния модел. MAE е по-стабилен към данни с отклонения. В проекта като loss-функция е ползвана MSE, а MAE е наблюдавана, чрез добавяне като метрика в compile().

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}|$$

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y})^2$$

Фигура 2

## Експериментални резултати

### 1. Модели

*Имплементацията на моделите, както и конкретика за архитектурите, метриките и хиперпараметрите са предоставени в Stock\_Market\_Price\_Predictor\_Base\_Models.ipynb и Stock\_Market\_Price\_Predictor\_Hybrid\_Models.ipynb в главната директория на проекта!*

В проекта са разгледани няколко базови архитектури от типа Many-to-One базирани на двата входни сета. На база анализите на тези базови модели са конструирани три хибридни модела с два входни клона, по които влизат двата типа данни, след което се обединяват. Очакванията бяха хибридните модели да подобрят резултатите от индивидуалните модели. В долната таблица (Таблица 1) са систематизирани архитектурите на моделите:

Таблица 1

Model	Type		Dataset	Branches	Layers	Optimizer
BiLSTM	Many-to-One	Simple	stocks_df.csv	1	2-Bidirectional 3-Dense	RMSprop
GRU-stocks_ds	Many-to-One	Simple	stocks_df.csv	1	2-GRU 3-Dense	Adam
Base Model	Many-to-One	Simple	company_dataset_ts.csv	1	4-Dense	RMSprop
LSTM	Many-to-One	Simple	company_dataset_ts.csv	1	6-LSTM 2-Dense	RMSprop
GRU-company_ds	Many-to-One	Simple	company_dataset_ts.csv	1	6-GRU 2-Dense	RMSprop
LSTM-GRU	Many-to-One	Hybrid	stocks_df.csv company_dataset_ts.csv	2	b1: 6-LSTM + 2 Dense b2: 2-GRU + 3-Dense concatenated + 3-Dense	RMSprop
LSTM-BiLSTM	Many-to-One	Hybrid	stocks_df.csv company_dataset_ts.csv	2	b1: 6-LSTM + 2 Dense b2: 2-BiLSTM + 3-Dense concatenated + 3-Dense	RMSprop
LSTM-GRU-short	Many-to-One	Hybrid	stocks_df.csv company_dataset_ts.csv	2	b1: 4-LSTM + 2 Dense b2: 2-GRU + 3-Dense concatenated + 3-Dense	RMSprop



## 2. Резултати и анализи

След тестване моделите отчетоха следните резултати (Таблица 2):

Таблица 2


Model	MAE	Epoch	Batch Size	Validation Split
BiLSTM	Test MAE: 0.08	90	128	-
GRU-stocks_ds	Test MAE: 0.07	150	128	0.225
Base Model	Test MAE: 0.10	120	128	0.25
LSTM	Test MAE: 0.05	70	128	0.225
GRU-company_ds	Test MAE: 0.04	65	128	0.225
LSTM-GRU	Test MAE: 0.05	150	128	0.225
LSTM-BiLSTM	Test MAE: 0.06	150	128	-
LSTM-GRU-short	Test MAE: 0.05	150	128	0.225

От направените анализи може да се направи заключение, че простите модели LSTM и GRU-company\_ds, работещи директно с данните свързани с акцията, се представят достатъчно добре и улавят финните движения на пазара. Комбинирането на тези прости архитектури в по-дълбоки хибридни модели обаче, влоши прогнозните резултати. Това разсейване може да се дължи на неправилната пропорция между данните или на недостатъчно прецизна архитектура/тренировка на невронната мрежа или просто на прекалено големият капацитет на мрежата. За тази цел, архитектурата на LSTM-GRU-short бе олекотена, което в голяма степен подобри резултата. На фигура е показана прогнозата генерирана от хибридният LSTM-GRU-short за целия разглеждан период и за отрязъка на прогнозния период:



На графиките (Фигура 3) са представени някои други примерни прогнози генерирани от моделите:


Base Model - company dataset - simple model



BiLSTM - stocks dataset - simple model




GRU - company dataset - simple model




GRU - stocks dataset - simple model



LSTM - company dataset - simple model



LSTM-GRU Hybrid



Фигура 3

## Заклучение

По-нататъшната работа по проекта ще бъде свързана с тестването на още няколко хибридни архитектури с различни капацитети. Могат да бъдат потърсени комбинации на характеристики от `stocks_df.csv`, при които да има случаен подбор на характеристики или да се пробват модели ползващи данните, определени като по-важни характеристики споменати в началото. Могат да бъде разширено разнообразието на сателитните характеристики с данни за пазарен сентимент, новини, твитове и т.н. Такива тестове бяха направени с включване на сентимент индикатор на твитове (TSI), но за съжаление данните за него са от 2018 година и не повлияха на резултатите на моделите, в които беше включен. Особено значими биха били данните от счетоводните отчети на компаниите. На настоящият етап от проекта това не беше възможно поради трудният и платен достъп по специфичен тип информация.

## Приноси

Основната новост в този проект, сравнявайки го със съществуващи разработки, бе подготовката на данните. **`Company_dataset_ts.csv`** бе изграден със специфична структура, като към генерираните времеви серии и стандартно изтеглените характеристики, бяха добавени 7 индикатора изчислени на база цена на затваряне. На практика, моделите, обучавани само с тези данни, показаха много добро представяне.

## Ползвани източници

1. *Deep Learning with Python, Second Edition, François Chollet*
2. <https://finance.yahoo.com/>
3. <http://colah.github.io/posts/2015-08-Understanding-LSTMs/>
4. <http://dprogrammer.org/rnn-lstm-gru>
5. <https://keras.io/api>
6. <https://www.tensorflow.org>
7. *google.com, github.com, stackoverflow.com (irreplaceable!)*